ARHITECTURA SISTEMELOR DE CALCUL SEMINAR 0x05

NOTIȚE SUPORT SEMINAR

Cristian Rusu

TIMPI CACHING, EX. 1

a) timpul total de acces memorie este (din curs)

1 ns +
$$(0.1 \times (5 \text{ ns} + (0.01 \times (10 \text{ ns} + (0.002 \times 50 \text{ ns})))))$$

în cazul nostru

1 ns +
$$(A \times (5 \text{ ns} + (0.01 \times (10 \text{ ns} + (0.002 \times 50 \text{ ns}))))) = t_{RAM} / 2$$

- b) $1 \text{ ns} + (0.1 \text{ x} (A \text{ ns} + (0.01 \text{ x} (10 \text{ ns} + (0.002 \text{ x} 50 \text{ ns}))))) = t_{RAM} / 10$
- c) $1 \text{ ns} + (0.1 \text{ x} (5 \text{ ns} + (0.01 \text{ x} (10 \text{ ns} + (A \text{ x} 50 \text{ ns}))))) = t_{RAM}$
- d) pentru L1, să trecem de la 1ns la 0.9ns ne costă 100\$ pentru L2, să trecem de la 5ns la 4.5ns ne costă 25\$ pentru L3, să trecem de la 10ns la 9ns ne costă 5\$

```
1x0.9^{A} + (0.1 \text{ x } (5x0.9^{B} + (0.01 \text{ x } (10x0.9^{C} + (0.002 \text{ x } 50))))) = t_{RAM}/1000 \text{ vrem: minimize } 100 \text{ x } A + 25 \text{ x } B + 5 \text{ x } C rezolvaţi pentru A, B şi C
```

ÎNTREBĂRI SCURTE, EX. 2

- a) utilizare CPU (eventual sisteme multi-core), media artimetică
- b) wall-clock time, media aritmetică
- c) memoria RAM, maximum
- d) performanță per Watt, media artimetică sau maximum
- e) wall-clock time, 50/90/99th percentile mediana
- f) wall-clock time speedup, media aritmetică
- g) minimum = când zgomotul/erorile din sistem sunt minime (*best-case behavior*), maximum = când zgomotul/erorile din sistem sunt maxime (*worst-case behavior*)
- h) dacă măsurăm cât mai bine și exact fiecare componentă, putem optimiza cât mai bine (semnificativ)

TIMPI DE RULARE, EX. 3

Test	Program A	Program B	A/B	B/A
1	9	3	3	0.33
2	8	2	4	0.25
3	2	20	0.1	10
4	10	2	5	0.2
Media	(a) 7.25	(a) 6.75	(g) 1.57	(g) 0.64

Concluzia: Program B este de 3 ori mai rapid decât Program A Concluzia: Program A este de 2.7 ori mai rapid decât Program B

Nu luați media aritmetică a rapoartelor A/B sau B/A Luați media geometrică a rapoartelor A/B sau B/A

• în acest caz, media rapoartelor este raportul medilor

TIMPI DE RULARE, EX. 3

Test	Program A	Program B	A/B	B/A
1	9	3	3	0.33
2	8	2	4	0.25
3	2	20	0.1	10
4	10	2	5	0.2
Media	(a) 7.25	(a) 6.75	(g) 1.57	(g) 0.64

Vrem să comparăm Program A vs. Program B: cine este mai rapid? A sau B?

- rulăm programele de mai multe ori
- comparăm linie cu linie în tabelul de mai sus
- pentru fiecare linie decidem cine câştigă (A sau B)
- apoi calculăm: care este probabilitatea ca A să fie mai rapid decât B dacă am observat că în n cazuri (din totalul de N) A este mai rapid decât B
- p-value

ÎNMULȚIRE COMPLEXĂ, EX. 4

- a) z = (a+bi)x(c+di) = ac bd + i(ad + bc)
- b) 2 adunări, 4 înmulțiri
- c) calculăm S1 = ac, S2 = bd şi S3 = (a+b)x(c+d)
 z = S1-S2 + i(S3-S1-S2)
 5 adunări, 3 înmulţiri
- d) C1 costul unei adunări
 C2 costul unei înmulțiri
 2C1 + 4C2 > 5C1 + 3C2

C2/C1 > 3

ÎNMULȚIRE MATRICE, EX. 4

e) algoritmul lui Strassen

vrem să calculăm C = AB (unde A și B sunt matrice)

```
for (i = 0; i < row_length_A; i++)
{
    for (k = 0; k < column_length_B; k++)
    {
        sum = 0;
        for (j = 0; j < column_length_A; j++)
        {
            sum += A[i][j] * B[j][k];
        }
        C[i][k] = sum;
    }
}</pre>
```

pe blocuri:

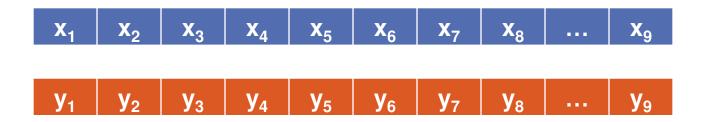
$$\mathbf{A} = egin{bmatrix} \mathbf{A}_{1,1} & \mathbf{A}_{1,2} \ \mathbf{A}_{2,1} & \mathbf{A}_{2,2} \end{bmatrix}, \mathbf{B} = egin{bmatrix} \mathbf{B}_{1,1} & \mathbf{B}_{1,2} \ \mathbf{B}_{2,1} & \mathbf{B}_{2,2} \end{bmatrix}, \mathbf{C} = egin{bmatrix} \mathbf{C}_{1,1} & \mathbf{C}_{1,2} \ \mathbf{C}_{2,1} & \mathbf{C}_{2,2} \end{bmatrix}$$

$$egin{aligned} \mathbf{C}_{1,1} &= \mathbf{A}_{1,1}\mathbf{B}_{1,1} + \mathbf{A}_{1,2}\mathbf{B}_{2,1} \ \mathbf{C}_{1,2} &= \mathbf{A}_{1,1}\mathbf{B}_{1,2} + \mathbf{A}_{1,2}\mathbf{B}_{2,2} \ \mathbf{C}_{2,1} &= \mathbf{A}_{2,1}\mathbf{B}_{1,1} + \mathbf{A}_{2,2}\mathbf{B}_{2,1} \ \mathbf{C}_{2,2} &= \mathbf{A}_{2,1}\mathbf{B}_{1,2} + \mathbf{A}_{2,2}\mathbf{B}_{2,2} \end{aligned}$$

$$egin{aligned} \mathbf{C}_{2,1} & \mathbf{C}_{2,2} \, \mathbf{J} \ & \mathbf{M}_1 := (\mathbf{A}_{1,1} + \mathbf{A}_{2,2}) (\mathbf{B}_{1,1} + \mathbf{B}_{2,2}) \ & \mathbf{M}_2 := (\mathbf{A}_{2,1} + \mathbf{A}_{2,2}) \mathbf{B}_{1,1} \ & \mathbf{M}_3 := \mathbf{A}_{1,1} (\mathbf{B}_{1,2} - \mathbf{B}_{2,2}) \ & \mathbf{M}_4 := \mathbf{A}_{2,2} (\mathbf{B}_{2,1} - \mathbf{B}_{1,1}) \ & \mathbf{M}_5 := (\mathbf{A}_{1,1} + \mathbf{A}_{1,2}) \mathbf{B}_{2,2} \ & \mathbf{M}_6 := (\mathbf{A}_{2,1} - \mathbf{A}_{1,1}) (\mathbf{B}_{1,1} + \mathbf{B}_{1,2}) \ & \mathbf{M}_7 := (\mathbf{A}_{1,2} - \mathbf{A}_{2,2}) (\mathbf{B}_{2,1} + \mathbf{B}_{2,2}) \end{aligned}$$

$$egin{aligned} \mathbf{C}_{1,1} &= \mathbf{M}_1 + \mathbf{M}_4 - \mathbf{M}_5 + \mathbf{M}_7 \ \mathbf{C}_{1,2} &= \mathbf{M}_3 + \mathbf{M}_5 \ \mathbf{C}_{2,1} &= \mathbf{M}_2 + \mathbf{M}_4 \ \mathbf{C}_{2,2} &= \mathbf{M}_1 - \mathbf{M}_2 + \mathbf{M}_3 + \mathbf{M}_6 \end{aligned}$$

produs scalar



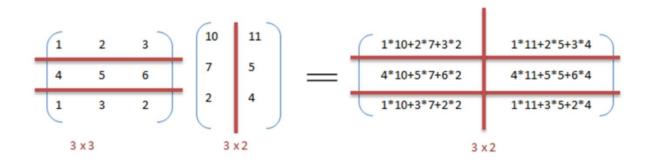
- $C += X_i Y_i$
- instrucțiune Fast Multiply-Add (fma)
- aceeași operație pe date diferite (SIMD)
- foarte uşor de paralelizat
 - atenție, rezultatul va fi diferit (adunarea nu mai e asociativă)
 - cu p procesoare ne aşteptăm să fim de p ori mai rapizi
- exploatează cache la maxim: datele sunt continue în memorie

produs matrice-vector

$$\begin{pmatrix}
2 & 3 \\
4 & 5 \\
-1 & 6
\end{pmatrix}
\iff
\begin{pmatrix}
4 \\
7
\end{pmatrix}
\iff
\begin{pmatrix}
(2*4)+(3*7) \\
(4*4)+(5*7)
\\
(-1*4)+(6*7)
\end{pmatrix}
\iff
\begin{pmatrix}
29 \\
51 \\
38
\end{pmatrix}$$

- $C += X_i Y_i$
- n produse scalare (se pot realiza în paralel)
- cum exploatăm eficient cache-ul?
 - dacă putem forța cache-ul să țină vectorul atunci cache miss rate va fi cu siguranță <= 50%

produs matrice-matrice



- $C += X_i Y_i$
- n^2 produse scalare (se pot realiza în paralel)
- dintre cele 3 variate din dreapta, care este mai rapidă în C? (testați și explicați)
- cum exploatăm eficient cache-ul?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int k = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

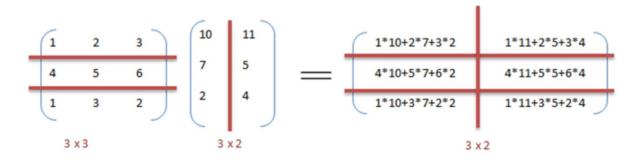
# varianta C
for (int k = 0; k < n; ++k)
  for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

produs matrice-matrice

- $C += X_i Y_i$
- n^2 produse scalare (se pot realiza în paralel)
- cum exploatăm eficient cache-ul?
 - calcul pe blocuri, nu pe linii sau coloane



produs matrice-matrice



- $C += X_i Y_i$
- n^2 produse scalare (se pot realiza în paralel)
- cum exploatăm eficient cache-ul?
 - calcul pe blocuri, nu pe linii sau coloane

```
for (ii = 0; ii < SIZE; ii += BLOCK_SIZE)
  for (kk = 0; kk < SIZE; kk += BLOCK_SIZE)
    for (jj = 0; jj < SIZE; jj += BLOCK_SIZE)
        maxi = min(ii + BLOCK_SIZE, SIZE);
        for (i = ii; i < maxi; i++)
            maxk = min(kk + BLOCK_SIZE, SIZE);
        for (k = kk; k < maxk; k++)
            maxj = min(jj + BLOCK_SIZE, SIZE);
        for (j = jj; j < maxj; j++)
            C[i][j] = C[i][j] + A[i][k] * B[k][j];</pre>
```

PERFORMANȚA MULTI-CORE, EX. 6

- a) $S_{Amdahl} = 1,78 \text{ și } S_{Gustafson} = 4,5$
- b) pentru Amdahl

dacă un program are timpul de execuție T atunci T = (1-p)T + pT (facem distincția între partea paralelizabilă și cea secvențială), dacă avem s core-uri atunci pT devine p/sT, deci accelerarea (raportul dintre timpul inițial și nou timp cu s core-uri) este S = T/((1-p)T + p/s T) = 1/(1-p + p/s)

pentru Gustafson

sistemul este capabil să execute E = (1-p)E + pE iar partea care se poate îmbunătății este doar pE, care devine δpE , deci execuția este îmbunătățită $((1-p)E + \delta pE)/E = 1 - p + \delta p$

- c) $S_{Amdahl} = 1$ și $S_{Gustafson} = 1$ (nicio îmbunătățire)
- d) $S_{Amdahl} = 1$ și $S_{Gustafson} = 1$ (nicio îmbunătățire)
- e) $L_{Amdahl} = 1/(1-p), S_{Amdahl} < 1/(1-p)$
- f) $L_{Gustafson} = \infty$
- g) verificați explicațile de la punct b) și țineți cont de rezultatele la limitele pentru p, s și δ

PERFORMANȚA CICLII, EX. 7

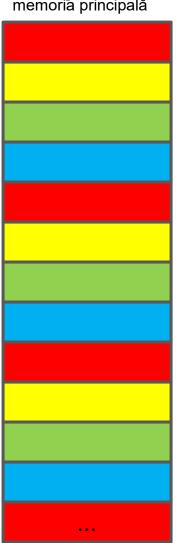
- a) 2.1
- b) 1.7
- c) înainte de modificare N x 2.1 / f, după N x 1.7 / f
- d) 1.48

PERFORMANȚA SISTEME, EX. 8

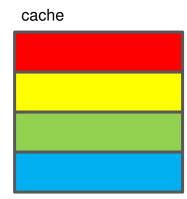
- a) p = 80/145, p = 40/145 şi p = 25/145 pentru sistemul X
 p = 50/140, p = 50/140 şi p = 40/140 pentru sistemul Y
- b) 2.24 pentru sistemul X și 2.86 pentru sistemul Y
- c) cpu time pe sistemul X = 145 x 2.24 / f
 cpu time pe sistemul Y = 140 x 2.86 / (1.2 x f)
 accelerarea este raportul valorilor: Y / X ≈ 1.03 (sistemul X este cu 3% mai rapid decât Y)

CACHE, EX. 9

- a) $2^{32} / 2^5 = 2^{27}$, $(2^4 \times 2^{10}) / 2^5 = 2^9 = 512$ blocuri
- b) un exemplu în care cache are doar 4 blocuri, cea mai simplă memoria principală



idee: un bloc din memoria principală dacă e în cache poate să fie doar într-o poziție din cache cu aceeași culoare

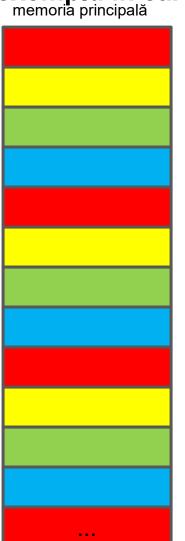


- 1) trebuie să știm ce culoare suntem
- 2) după ce știm culoare, trebuie să știm care block din memoria principală este cel corect (din toate cele roșii)
- 3) trebuie să știm unde în bloc este byte-ul pe care îl vrem

TAG	INDEX	OFFSET
-----	-------	--------

CACHE, EX. 9

- a) $2^{32} / 2^5 = 2^{27}$, $(2^4 \times 2^{10}) / 2^5 = 2^9 = 512$ blocuri
- b) un exemplu în care cache are doar 4 blocuri, cea mai simplă



idee: un bloc din memoria principală dacă e în cache poate să fie doar într-o poziție din cache cu aceeași culoare

tehnica aceasta de 1 la 1 se numește *direct mapping* dacă un bloc din memoria principală poate să fie în mai multe blocuri din cache (nu doar unul singur) atunci tehnica se numește *N-set associative mapping* (unde N este numărul de blocuri din cache în care un bloc din memorie poate fi copiat (este fie acolo, fie nu e in cache)

această nouă tehnică oferă mai multa flexibilitate (1 la 1 este prea limitat)

- 1) trebuie să știm ce culoare suntem
- 2) după ce știm culoare, trebuie să știm care block din memoria principală este cel corect (din toate cele roșii)
- 3) trebuie să știm unde în bloc este byte-ul pe care îl vrem

18 biţi (ce rămâne pentru a identificare care bloc de aceeaşi culoare e cel corect)

9 biţi (pentru că sunt 2⁹ = 512 blocuri/culori în cache)

5 biţi (pentru că sunt 2⁵ = 32 bytes posibili în bloc)