Instrumente si Tehnici de Baza in Informatica

Semestrul I 2024-2025

Vlad Olaru

Curs 7 - outline

- filtre
- editarea automata a textelor
- procesarea automata a textelor

Procesare text: cmd1 | filtru | cmd2

Vocabular

- filtru – program, comandă, operatie care procesează iesirea în format text a unei comenzi astfel încât noua formă să poată fi procesată mai departe de utilizator sau de un alt program
- linie – sir de caractere care se termină cu \n (sau \r\n în Windows)
- separator (sau delimitator) – caracter sau sir folosit pentru a delimita datele într-o linie
- câmp (*field*) – un subsir dintr-o linie care reprezintă un anumit tip de date
- exemplu:
  - linie: nume prenume grupă serie
  - separator: " "
  - câmpuri: nume, prenume, grupă si serie

cut(1)

`cut(1)` extrage câmpuri din fiecare linie primită la intrare

- `list` – numere sau intervale separate de virgulă sau spatii
- `-b list` – lista contine pozitii în bytes
- `-c list` – lista contine pozitiile caracterelor
- `-f list` – lista specifică câmpuri
- `-d delim` – specifică delimitatorul pentru câmpuri (implicit este \t)
- `-n` – nu împarte caractere multi-byte în bytes
- `-s` – sare peste liniile care nu contin delimitatoare

Tipuri de apel

- `cut -b [-n] list [file ...]`
- `cut -c list [file ...]`
- `cut -f list [-s] [-d delim] [file ...]`

Exemple: cut(1)

Afisează numele și shellurile folosite de utilizatorii din sistem:

```
$ cut -d : -f 1,7 /etc/passwd
nobody:/sbin/nologin
paul:/bin/ksh
build:/bin/ksh
joe:/bin/ksh
_mysql:/sbin/nologin
_postgresql:/bin/sh
souser:/bin/ksh
alex:/bin/ksh
```

Exemple: cut(1)

Arată numele si data la care s-au logat utilizatorii activi:

```
$ who | cut -c 1-8,18-30

deraadt  May   8 18:32
dlg      May   3 20:39
jsing    Apr  28 06:47
landry   Apr  19 14:22
deraadt  Apr  19 08:24
kettenis May   9 02:47
deraadt  May   3 22:18
pirofti  May   9 04:36
```

paste(1)

Lipeste fisierele primite la intrare pe coloane (pe verticală)

- -d list – foloseste delimitatorul pentru a înlocui caracterul linie nouă \n din fiecare fisier
- -s – serializare
- \- – reprezintă intrarea standard (stdin)

Apel

- paste [-s] [-d list] file ...

Exemplu: paste(1)

Fie fisierele cu nume și prenume:

```
$ echo "Paul\nAlex\nAna" > firstnames.txt
$ echo "Irofti\nAlexandrescu\nPopescu" \
        > lastnames.txt
```

Implicit, paste(1) lipeste numele de prenume

```
$ paste firstnames.txt lastnames.txt
Paul    Irofti
Alex    Alexandrescu
Ana     Popescu
```

Acelasi lucru dar cu serializare

```
$ paste -s firstnames.txt lastnames.txt
Paul    Alex    Ana
Irofti  Alexandrescu    Popescu
```

Exemplu: paste(1)

Afisează fisierele din directorul curent pe trei coloane:

```
$ ls | paste - - -
1       10      11
2       3       4
5       6       7
8       9       intro
```

Identic cu apelul `ls | paste -s -d '\t\t\n' -`

Crează o listă de directoare bin din sistem separate prin :

```
$ find / -name bin -type d | paste -s -d : -
/usr/X11R6/bin:/usr/local/bin:
/usr/local/lib/qt4/bin:
...
```

split(1)

Împarte fisierul dat în mai multe fisiere de 1000 de linii fiecare.

- `-a suffix_length` – câte litere să conțină sufixul noilor fisiere
- `-b byte_count` – crează fisiere de lungimea dată în bytes
- `-l line_count` – crează fisiere cu numărul de linii dat
- `file` – fisierul de împărtit, implicit este `stdin`
- `name` – prefixul pentru noile fisiere

Apel

- `split [options] [file [name]]`

Implicit crează fisierele `xaa`, `xab`, `xac`, ...

Exemplu: split(1)

- Împarte fisierul LaTeX în mai multe fisiere de 100 de linii:

```
$ wc -l fisier.tex
     362 fisier.tex
$ split -l 100 fisier.tex
$ ls x*
xaa xab xac xad
$ wc -l x*
      100 xaa
      100 xab
      100 xac
       62 xad
      362 total
```

Acelasi lucru dar cu prefix fisier și o singură literă sufix:

```
$ split -a 1 -l 100 fisier.tex fisier
```

join(1)

Alăturează linii care contin chei identice din două fisiere diferite

- `file1, file2` – fisierele de intrare
- `-1 field` – câmpul cheie din fisierul 1
- `-2 field` – câmpul cheie din fisierul 2
- `-a file_number` – produce o linie pentru fiecare nepotrivire din fisierul dat (1 sau 2)

Apel

- `join [-1 field] [-2 field] [options] file1 file2`

Exemplu: join(1)

Alătură persoanele pentru care exista date legate de vârstă și venit:

```
$ cat age.txt
Paul 33
Alex 40
Ana  25
$ cat income.txt
Paul 3000
Ana  4500
$ join age.txt income.txt
Paul 33 3000
Ana 25 4500
```

Acelasi lucru dar include si persoanele (ex. Alex) fără venit:

```
$ join -a1 age.txt income.txt
```

Basic Calculator – bc(1)

Calculator pentru operatii aritmetice și logice

- `-l` – permite operatii cu numere în virgulă mobilă
- `-e expr` – evaluează expresia, pot fi mai multe
- `file` – preia expresii din fisier
- operatorii binari sunt la fel ca in C
- operatorii logici &&, || si ! sunt disponibili în unele implementări dar nu sunt specificati de standardul POSIX
- reprezintă un limbaj de sine stătător cu blocuri de control (ex. while)
- implicit porneste un shell specializat si asteaptă comenzi

Apel

- `bc [-l] [-e expr] [file]`

bc(1)– functii

- `s(x)` – sinus
- `c(x)` – cosinus
- `e(x)` – exponent
- `l(x)` – logaritm
- `a(x)` – arctangent
- `sqrt(x)` – radical
- `scale=n` – precizie, *n* numere zecimale
- `quit` – terminare program

Exemplu: bc(1)

Operatii de bază:

```
$ echo "1/3" | bc
0
$ echo "1/3" | bc -l
.33333333333333333333
$ echo "1>3" | bc -l
0
$ echo "1<3" | bc -l
1
$ bc -l -e "sqrt(2)" -e quit
1.41421356237309504880
```

Exemplu: bc(1)

```
$ bc -l
scale=4
sqrt(3)
1.7320
4*a(1)
3.1412
c(4*a(1))
-1.0000
c(4*s(1))
-.9750
quit
```

Translate – tr(1)

`tr(1)` traduce caractere primite din `stdin` si afisează rezultatul la `stdout`

`string1, string2` – caracterele din primul sir sunt traduse ca cele din al doilea string

`-C,-c` – aplică complementul setului de caractere din `string1`

`-d` – sterge caracterele ce apar în `string1`

`-s` – elimină duplicatele traduse conform ultimul operand (fie `string1` fie `string2`)

Tipuri de apel:

- `tr [-Ccs] string1 string2`
- `tr [-Cc] -d string1`
- `tr [-Cc] -s string1`

Exemplu: tr(1)

Crează o listă de cuvinte primite la intrare:

```
$ echo "Ana are mere" | tr -cs "[A-Za-z]" "\n"
Ana
are
mere
```

Scrie textul primit cu majuscule

```
$ echo "Ana are mere" | tr "[a-z]" "[A-Z]"
ANA ARE MERE
```

Obtine sirurile de caractere dintr-un fisier binar:

```
$ echo "int main(){return 0;}"|cc -xc -o test -
$ cat test | tr -cd "[:print:]"
ELF > @@8@@@@ >>>>>>>>HH H XX X @@TTTPtd44eHH H
...
```

Stream EDitor – sed(1)

sed(1) este un editor de text în toată regula, mai mult este chiar un limbaj de programare!

- folosit în general pentru substitutii și eliminări de text
- diferit de tr(1) foloseste expresii regulate
- mod de functionare
  - parcurge linie cu line intrarea căutând un tipar
  - dacă a găsit un sir de caractere care respectă tiparul aplică functia dată de utilizator asupra acestuia
  - functiile pot fi predefinite (substitutie, eliminare) sau scrise de utilizator

Apel:

- `sed [options] command [file ...]`

Exemple: sed(1)

Substitutie s,tipar,text,

```
$ echo "Paul Alex Ana" | sed s,Alex,Paul,
Paul Paul Ana
$ echo "Paul Alex Alex Ana" | sed s,Alex,Paul,
Paul Paul Alex Ana
```

Substitutie s,tipar,text,flag

```
$ echo "Paul Alex Alex Ana" | sed s,Alex,Paul,g
Paul Paul Paul Ana
$ echo "Paul Alex Alex Ana" | sed s,Alex,Paul,2
Paul Alex Paul Ana
$ echo "Paul Alex Ana" | sed s,Alex,Paul,wfile
Paul Paul Ana
$ cat file
Paul Paul Ana
```

Exemplu: sed(1)

Eliminarea linilor care contin tiparul:

```
$ echo "Paul Alex\nAlex Ana" | sed /Paul/d
Alex Ana
```

Dacă vrem să stergem doar sirul de caractere:

```
$ echo "Paul Alex\nAlex Ana" | sed s/Paul//g
 Alex
Alex Ana
```

Aplicare doar anumitor linii:

```
$ echo "Paul\nAlex\nAlex\nAna\nPaul\nGeorge" | \
       sed 1,3 s/Paul//g

Alex
Alex
Ana
Paul
George
```

Exemplu: sed(1)

Inversarea a două cuvinte folosind expresii regulate

```
$ echo "Paul Irofti\nAlex Pop\nGeorge Stan" | sed 's
  ,^\([A-Z][A-Za-z]*\) \([A-Z][A-Za-z]*\),\2 \1,'
Irofti Paul
Pop Alex
Stan George
```

- ^ – caută un tipar la începutul liniei
- [A-Z] – trebuie să înceapă cu majusculă
- [A-Za-z]* – poate continua cu oricâte litere mici sau mari
- () – demarcă două expresii în tipar; folosim \ ca să nu fie interpretate de shell (*escaping*)
- \1 \2 – sirurile care au fost găsite cu cele două expresii

Există și jocuri scrise în sed(1)

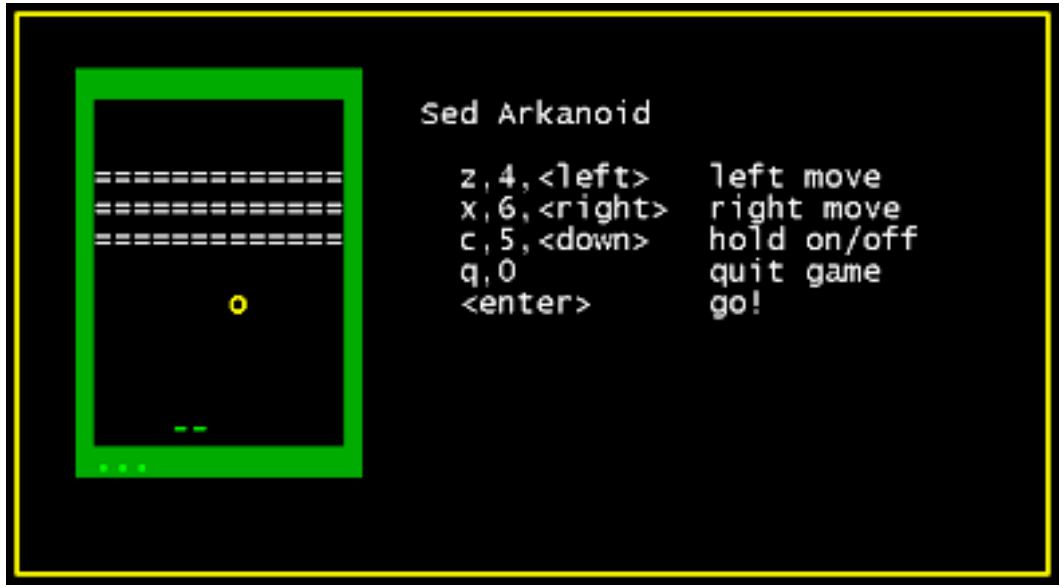

http://aurelio.net/projects/sedarkanoid/

awk(1)

Limbaj de programare specializat pentru procesarea datelor de tip text

- Alfred **A**ho, Peter **W**einberger și Brain **K**ernighan (1970)
- functionează pe principiul identificare tipar - aplicare functie ca sed(1)
- verifică mai mult de un tipar

```
tipar1 { comenzi }
tipar2 { comenzi }
```

- verifică linia curentă cu fiecare tipar dat după care trece la următoarea linie

- Turing Complete

Apel:

- awk [options] [program] file ...

Exemple: awk(1)

Afisează linile care contin tiparul

```
$ echo "Paul Irofti\nAlex Pop\nGeorge Stan" | awk '/
    Pop/ {print}'
Alex Pop
```

Găseste de câte ori apare un sir în fisier:

```
$ echo "Dori si Nemo\nNemo la dentist\nDori s-a
    pierdut" | \
> awk 'BEGIN {print "Finding Nemo and Dori"}
> /[Nn]emo/ {nemo++}
> /[Dd]ori/ {dori++}
> END {print "Found Nemo " nemo " times and Dori "
    dori " times!"}'
Finding Nemo and Dori
Found Nemo 2 times and Dori 2 times!
```

Comenzile marcate cu BEGIN si END se execută doar o dată.

Exemple: awk(1)

Procesarea câmpurilor dintr-un fisier

- $0 – se referă la linia întreagă
- $1,$2,...,$(10) – se referă la fiecare câmp în parte
- FS(*field separator) – este separatorul; implicit setat ca spatiu*

```
$ cat cont.txt
OP        SUM
IN        10
OUT       5
IN        20
IN        3
OUT       25
$ awk '
> BEGIN {print "Fonduri disponibile"; fonduri = 0}
> /IN/ { fonduri += $2 }
> /OUT/ {fonduri -= $2 }
> END {print fonduri "RON"}' cont.txt
Fonduri disponibile
3RON
```

awk(1): variabile si functii

Variabile utile

- NF – numărul de câmpuri în linia curentă
- NR – numărul de linii citite până acum
- FILENAME – numele fisierului de intrare

Functii utile

- `toupper()`,`tolower()` – litere mari, litere mici
- `exp()`,`log()`,`sin()` – functii matematice
- `length()` – lungimea sirului
- `int()` – partea întreagă

Exemple: awk(1)

Afis,ează toate cuvintele:

```
$ echo "Ana are mere" | \
  awk '{for (i=1;i<=NF;i++) print $i }'
Ana
are
mere
```

Listă cu utilizatori si shell folosit:

```
$ awk 'BEGIN { FS = ":" }
> {print "User " $1 " uses " $7 " shell."}'
> /etc/passwd

User nobody uses /sbin/nologin shell.
User paul uses /bin/ksh shell.
User souser uses /bin/ksh shell.
User _rsync uses /sbin/nologin shell.
User alex uses /usr/local/bin/bash shell.
```

Exemple: awk(1)

Afisează doar numele shellului pentru un utilizator anume:

```
$ awk 'BEGIN { FS = ":" }
> /paul/ { cmd = "basename " $7;
> cmd | getline shell;
> print "User " $1 " uses " shell " shell."
> close(cmd);
> }' /etc/passwd
User paul uses ksh shell.
```

Execută o comandă externă si obtine rezultatul cu `getline`.