

LABORATOR #10

EX#1 (Covarianță și corelație)

Covarianța și corelația a două variabile aleatoare X și Y sunt definite ca:

$$\begin{aligned}\text{Cov}(X, Y) &:= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]; \\ \text{Corr}(X, Y) &:= \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)},\end{aligned}$$

unde reamintim definiția deviației standard: $\sigma(X) := \sqrt{\text{Var}(X)} := \sqrt{\mathbb{E}[(X - \mathbb{E}[X])^2]}$.
Observații:

- Dacă X și Y sunt independente, atunci covarianța și corelația lor sunt egale cu zero.
- Corelația este o mărime adimensională și ia valori în intervalul $[-1, 1]$.

Aproximarea numerică a covarianței (Covarianța Eșantionului):

Fie $(X_1, Y_1), (X_2, Y_2), \dots, (X_N, Y_N)$ perechi independente de variabile aleatoare cu aceeași distribuție, având medie și varianță finite. Mai precis, pentru orice $a, b \in \mathbb{R}$ și $i \in \overline{2, N}$,

$$\mathbb{P}(X_i \leq a \cap Y_i \leq b) = \mathbb{P}(X_1 \leq a \cap Y_1 \leq b),$$

iar dacă $i \neq j$ și $a, a', b, b' \in \mathbb{R}$, atunci avem:

$$\mathbb{P}((X_i \leq a \cap Y_i \leq b) \cap (X_j \leq a' \cap Y_j \leq b')) = \mathbb{P}(X_i \leq a \cap Y_i \leq b) \mathbb{P}(X_j \leq a' \cap Y_j \leq b').$$

Dacă notăm

$$\text{Cov}_N := \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_N)(Y_i - \bar{Y}_N),$$

atunci

$$\text{Cov}_N \xrightarrow{\text{aproape sigur}} \text{Cov}(X_1, Y_1)$$

și

$$\mathbb{E}[\text{Cov}_N] = \text{Cov}(X_1, Y_1).$$

#1 La aruncarea a două zaruri, considerăm următoarele variabile aleatoare:

- X = valoarea primului zar
- Y = suma celor două zaruri.

Aproximați empiric prin simulări repetate covarianța și corelația celor două variabile aleatoare.

#2 Fișierul `data_file.py` conține funcția `get_data(<key>)`. Apelând `get_data("geyser")`, obținem un dicționar ce conține la cheia `"eruptions"` un vector cu durata (în minute) a mai multor erupții ale unui gheizer din Parcul Național Yellowstone, SUA. La cheia `"waiting"` se află un vector de aceeași lungime ce conține timpul (în minute) până la următoarea erupție. Calculați covarianța și corelația dintre durata erupțiilor și timpul până la următoarea erupție.

#3 Aceeași funcție apelată de data aceasta `get_data("cars")` returnează un dicționar cu date despre mașini. La cheia `"tons"` se află un vector cu masa mașinilor, la cheia `"range"` se află un vector de aceeași lungime cu numărul de kilometri parcurși utilizând un litru de combustibil, iar la cheia `"hp"` se află un vector cu puterea mașinii exprimată în cai putere. Calculați covarianța și corelația fiecărei perechi de caracteristici ale mașinilor.

EX#2 (Regresia liniară – preziceri ale unor date necunoscute)

Regresia liniară simplă. Considerăm un set de date de forma $(x_i, y_i)_{i=1}^N$ și dorim să găsim o relația liniară care aproximează cel mai bine dependența caracteristicilor y_i de caracteristicile x_i . Prin urmare, vrem să găsim dreapta de ecuația $y = ax + b$ care aproximează *cel mai bine* setul de date, în sensul minimizării următoarei erori (numită eroarea în sensul *celor mai mici pătrate*):

$$\text{Err}_{\text{LS}}(a, b) := \sum_{i=1}^N (y_i - ax_i - b)^2.$$

Desfacem parantezele și obținem:

$$\text{Err}_{\text{LS}}(a, b) = a^2 \sum_{i=1}^N x_i^2 + Nb^2 + 2ab \sum_{i=1}^N x_i - 2a \sum_{i=1}^N x_i y_i - 2b \sum_{i=1}^N y_i.$$

În cazul nedegenerat când nu avem toate valorile x_i egale, funcția este strict convexă, deci minimul global coincide cu unicul punct critic. Prin derivare parțială, obținem:

$$\begin{aligned} \partial_a \text{Err}_{\text{LS}}(a, b) &= 2a \sum_{i=1}^N x_i^2 + 2b \sum_{i=1}^N x_i - 2 \sum_{i=1}^N x_i y_i; \\ \partial_b \text{Err}_{\text{LS}}(a, b) &= 2Nb + 2a \sum_{i=1}^N x_i - 2 \sum_{i=1}^N y_i. \end{aligned}$$

Egalăm cele două derivate parțiale cu zero și obținem sistemul:

$$\begin{pmatrix} \sum_{i=1}^N x_i^2 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & N \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{pmatrix}.$$

În cazul nedegenerat, matricea e inversabilă deci putem rezolva sistemul și determinăm valorile a și b .

Regresia liniară cu două variabile de intrare. Considerăm acum setul de date $(x_i, y_i, z_i)_{i=1}^N$ și vrem să aproximăm liniar dependența valorilor z_i de valorile x_i și y_i . Prin urmare, vrem să găsim coeficienții a, b, c astfel încât planul de ecuație $z = ax + by + c$ să aproximeze cel mai bine setul de date. Eroare în sensul celor mai mici pătrate devine:

$$\text{Err}_{\text{LS}}(a, b) := \sum_{i=1}^N (z_i - ax_i - by_i - c)^2.$$

Procedând analog, în cazul nedegenerat în care nu toate punctele (x_i, y_i) din setul de date sunt coliniare, obținem:

$$\begin{pmatrix} a \\ b \\ c \end{pmatrix} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Z},$$

unde:

$$\mathbf{X} = \begin{pmatrix} x_1 & y_1 & 1 \\ x_2 & y_2 & 1 \\ \vdots & \vdots & \vdots \\ x_N & y_N & 1 \end{pmatrix} \quad \text{și} \quad \mathbf{Z} = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_N \end{pmatrix}.$$

#1 Afișați într-un sistem de coordonate xOy setul de date "**geyser**" de la Ex#1, împreună cu dreapta de regresie a timpului până la următoarea erupție în funcție de durata unei erupții.

Preziceți, folosind dreapta de regresie obținută, câte minute vom aștepta până la următoarea erupție, dacă erupția curentă a durat 6 minute.

#2 Aceeași cerință pentru setul de date "**cars**", în care să afișați dreapta de regresie a distanței parcurse cu un litru de combustibil în funcție de puterea mașinii.

#3 Preziceți câți kilometri putem parcurge cu un rezervor plin cu 40 de litri de combustibil, pentru o mașină de 2 tone și 97 cai putere, folosind regresia liniară a setului de date "**cars**".